

Optimaliseren van gegevensverwerking in Microsoft Azure: Een vergelijkende analyse van implementatiemethoden voor Extractie, Transformatie en Laden (ETL) en Extractie, Laden en Transformatie (ELT).

Optionele ondertitel.

Lievens Loeka.

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

Promotor: Dhr. Bosteels Gertjan

Co-promotor: Dhr. Van Damme Koen

Academiejaar: 2023–2024

Eerste examenperiode

Departement IT en Digitale Innovatie .

**HO
GENT**

Woord vooraf

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Samenvatting

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Inhoudsopgave

Lijst van figuren	vii
1 Inleiding	1
1.1 Probleemstelling	1
1.2 Onderzoeksvraag	2
1.3 Onderzoeksdoelstelling	2
1.4 Opzet van deze bachelorproef	2
2 Stand van zaken	3
2.1 Wat zijn ETL's of ELT's?	3
2.2 Welke soorten ETL tools bestaan er?	3
2.3 Populairste cloud-based ETL tools	4
2.4 Azure Data Factory (ADF)	4
2.4.1 Onderdelen	4
2.4.2 Mapping Data Flows	5
2.5 Azure Databricks	6
2.5.1 Delta Lake	6
2.5.2 Delta Live Tables	6
3 Methodologie	7
3.1 Literatuuronderzoek	7
3.2 Long list	7
3.3 Short list	7
3.4 Vergelijkingscriteria	8
3.4.1 Kostprijs	8
3.4.2 Performantie	8
3.4.3 Mogelijkheid tot debuggen	8
3.4.4 Verschil in implementatietijd	8
3.4.5 Moeilijkheidsgraad in opzet	8
3.4.6 Mogelijkheden van de tool	8
3.4.7 Onderhoudbaarheid	8
3.4.8 Testbaarheid	8
3.5 Proof-of-concepts	8
3.5.1 Azure Data Factory (ADF)	8
3.5.2 Azure Databricks	18
3.5.3 Collaboration en source control	22

4 Conclusie	24
A Onderzoeksvoorstel	26
A.1 Inleiding	26
A.2 Literatuurstudie	27
A.3 Methodologie	28
A.4 Verwacht resultaat, conclusie	29
Bibliografie	30

Lijst van figuren

1

Inleiding

De inleiding moet de lezer net genoeg informatie verschaffen om het onderwerp te begrijpen en in te zien waarom de onderzoeksvraag de moeite waard is om te onderzoeken. In de inleiding ga je literatuurverwijzingen beperken, zodat de tekst vlot leesbaar blijft. Je kan de inleiding verder onderverdelen in secties als dit de tekst verduidelijkt. Zaken die aan bod kunnen komen in de inleiding (Pollefliet, 2011):

- context, achtergrond
- afbakenen van het onderwerp
- verantwoording van het onderwerp, methodologie
- probleemstelling
- onderzoeksdoelstelling
- onderzoeksvraag
- ...

1.1. Probleemstelling

Uit je probleemstelling moet duidelijk zijn dat je onderzoek een meerwaarde heeft voor een concrete doelgroep. De doelgroep moet goed gedefinieerd en afgelijnd zijn. Doelgroepen als “bedrijven,” “KMO’s”, systeembeheerders, enz. zijn nog te vaag. Als je een lijstje kan maken van de personen/organisaties die een meerwaarde zullen vinden in deze bachelorproef (dit is eigenlijk je steekproefkader), dan is dat een indicatie dat de doelgroep goed gedefinieerd is. Dit kan een enkel bedrijf zijn of zelfs één persoon (je co-promotor/opdrachtgever).

1.2. Onderzoeksvraag

Wees zo concreet mogelijk bij het formuleren van je onderzoeksvraag. Een onderzoeksvraag is trouwens iets waar nog niemand op dit moment een antwoord heeft (voor zover je kan nagaan). Het opzoeken van bestaande informatie (bv. “welke tools bestaan er voor deze toepassing?”) is dus geen onderzoeksvraag. Je kan de onderzoeksvraag verder specificeren in deelvragen. Bv. als je onderzoek gaat over performantiemetingen, dan

1.3. Onderzoeksdoelstelling

Wat is het beoogde resultaat van je bachelorproef? Wat zijn de criteria voor succes? Beschrijf die zo concreet mogelijk. Gaat het bv. om een proof-of-concept, een prototype, een verslag met aanbevelingen, een vergelijkende studie, enz.

1.4. Opzet van deze bachelorproef

De rest van deze bachelorproef is als volgt opgebouwd:

In Hoofdstuk 2 wordt een overzicht gegeven van de stand van zaken binnen het onderzoeksdomein, op basis van een literatuurstudie.

In Hoofdstuk 3 wordt de methodologie toegelicht en worden de gebruikte onderzoekstechnieken besproken om een antwoord te kunnen formuleren op de onderzoeksvragen.

In Hoofdstuk 4, tenslotte, wordt de conclusie gegeven en een antwoord geformuleerd op de onderzoeksvragen. Daarbij wordt ook een aanzet gegeven voor toekomstig onderzoek binnen dit domein.

2

Stand van zaken

Bedrijven slaan veel data op. Doordat deze data nuttig kan zijn voor het identificeren van nieuwe kansen is het belangrijk om deze data klaar te maken voor business analytics. Dit is het proces van verzamelen, organiseren, analyseren en interpreteren van gegevens om inzichten te krijgen. Er kan bijvoorbeeld gekeken worden naar klantgegevens om zo patronen en trends te vinden in het gedrag van de klant. (J., [2023](#))

Doordat bedrijven vaak werken met veel verschillende soorten data dat op verschillende plekken opgeslaan wordt, is het vaak belangrijk dat deze data eerst opgekuist, getransformeerd en georganiseerd moet worden. Dit is waarbij het implementeren van ETL's en ELT's van pas komt. (Inmon, [2023](#))

2.1. Wat zijn ETL's of ELT's?

ETL's en ELT's zijn processen die organisaties gebruiken voor het verzamelen en samenvoegen van data uit meerdere bronnen. Bij ETL's wordt de data getransformeerd voor het naar de doelopslagplaats geladen wordt, terwijl dit bij ELT's pas achteraf gebeurt. Daardoor staat ETL voor Extract, Transform and Load en ELT voor Extract, Load and Transform. (Bartley, [2023](#))

2.2. Welke soorten ETL tools bestaan er?

Er bestaan verschillende soorten ETL tools. Zo zijn er de cloud-based ETL tools. Deze worden gehost op cloud infrastructure, zijn zeer schaalbaar en bieden pay-as-you-go prijs modellen aan. (Ethan, [2024](#))

Daarnaast zijn er ook on-premises ETL tools. Deze worden gehost op de infrastructuur van het bedrijf waardoor het bedrijf er de volledige controle over heeft. (Ethan, [2024](#))

Afhankelijk van wat men nodig heeft kan er ook gekozen worden voor hybrid ETL

tools. Dit is een combinatie van het gebruik van cloud-based tools met het gebruik van on-premises tools. (Ethan, 2024)

Ten slotte zijn er ook open source ETL tools. Dit zijn gratis ETL tools. Voorbeelden hiervan zijn Portable, Apache NiFi, AWS Glue, Airbyte en Informatica. (Ethan, 2024)

2.3. Populairste cloud-based ETL tools

Zoals te zien in de enquête van Vines en Tanasescu (2023) is Microsoft Azure, gevolgd door Amazon Web Services (AWS) en Google Cloud Services, de populairste cloud provider. Deze cloud-providers bieden dan ook de meest populaire cloud-based ETL tools aan.

Microsoft biedt bijvoorbeeld Azure Data Factory en Azure Databricks aan. Binnen Azure Data Factory kan er gebruik gemaakt worden van Mapping Data Flows, dit is een code-vrije manier waarmee ETL's opgebouwd kunnen worden. De logica achter de ETL kan hierna makkelijk getest worden op live data en samples. (Kromer, 2022b)

Daarnaast biedt Azure ook Azure Databricks aan. Het verschil hierbij is dat de ETL's worden geïmplementeerd via code terwijl dat bij Azure Data Factory via de UI tools gebeurt. Azure Databricks is gebaseerd op het Apache Spark opensource project. Het grote voordeel is dat het platform het toelaat om makkelijker te kunnen samen werken. Daarnaast is Apache Spark niet enkel gelimiteerd tot het maken van ETL's maar kan het ook gebruikt worden voor real-time analytics, machine learning, graph processing, etc. (Etaati, 2019)

Ook Amazon Web Services (AWS) en Google Cloud Services bieden ETL tools aan. Zo heeft AWS bijvoorbeeld AWS Glue (Khan e.a., 2024) en Google Cloud heeft Google Data Fusion. (Jaiswal, 2022)

2.4. Azure Data Factory (ADF)

Azure Data Factory is een platform-as-a-service (PAAS) voor het implementeren van ETL's en ELT's. Zowel on-premises als cloudgegevensbronnen worden hierbij ge ondersteund voor het verplaatsen van gegevens. (Rawat & Narain, 2018)

2.4.1. Onderdelen

Azure Data Factory is opgebouwd uit verschillende onderdelen. Als eerste hebben we een pipeline. Dit is een groep van activiteiten die een reeks processen uitvoert zoals bijvoorbeeld het extraheren of transformeren van gegevens. Een voorbeeld van een activity is een Mapping Data Flow. Hiermee kan men logica voor datatransformaties ontwikkelen zonder code te schrijven. Daarnaast zijn er ook datasets. Dit is een representatie of verwijzing naar de daadwerkelijke gegevens in gegevens-opslag. Een dataset is steeds gekoppeld aan een linked service. Deze slaan de informatie op die Azure Data Factory nodig heeft voor het connecteren naar een

externe dataopslag. Een pipeline wordt uitgevoerd door een trigger. Er zijn veel verschillende soorten triggers voor veel verschillende soorten events. Daarnaast kan er voor een pipeline parameters gedefinieerd worden. Dit zijn read-only key-value pairs die een configuratie vormen. Ook kunnen er variables gebruikt worden om tijdelijk waarden op te slaan. In combinatie met parameters kunnen dan waarden tussen pipelines, data flows, en andere activiteiten doorgegeven worden. Wanneer een pipeline wordt uitgevoerd zal er een pipeline run aangemaakt worden. (Microsoft, 2024d)

2.4.2. Mapping Data Flows

Met behulp van Mapping Data Flows kunnen ETL's geïmplementeerd worden zonder hiervoor gebruik te moeten maken van code. De resulterende data flows worden uitgevoerd als activiteiten binnen een Azure Data Factory pipeline dat gebruik maakt van Apache Spark Clusters. Deze Mapping Data Flows maken gebruik van data flow scripts. Dit zijn artifacten die gegenereerd worden door de UI. Het is een taal die de data transformatie beschrijft dat de Spark Cluster zal moeten uitvoeren. De UI van Azure Data Factory beheert het data flow script maar het script kan ook bekeken en handmatig bewerkt worden. (Kromer, 2022a)

In Mapping Data Flows kunnen verschillende soorten transformaties gedaan worden:

- Multiple inputs/outputs
 - New Branch
 - Join
 - Conditional Split
 - Exists
 - Union
 - Lookup
- Schema modifier
 - Derived Column
 - Select
 - Aggregate
 - Surrogate Key
 - Pivot
 - Unpivot
 - Window
 - Rank

- External Call
- Formatters
 - Flatten
 - Parse
 - Stringify
- Row modifier
 - Filter
 - Sort
 - Alter Row
 - Assert
- Flowlets
 - Flowlet
- Destination
 - Sink

2.5. Azure Databricks

Azure Databricks is een geavanceerd platform voor data-analyse dat zich integreert met Azure services. Het biedt een complete omgeving voor het ontwikkelen, implementeren en delen van krachtige data-analyses en AI-toepassingen op grote schaal. Het integreert zich ook met de opensource-community zoals bijvoorbeeld Delta Lake, Delta Sharing, MLflow, Apache Spark en Redash. Veel voorkomende use cases van Azure Databricks zijn het bouwen van een data lakehouse voor ondernemingen, het implementeren van ETL's, gebruik van machine learning en dergelijke. (Microsoft, [2024b](#))

2.5.1. Delta Lake

Delta Lake is het standaard opslagformaat voor alle operaties binnen Azure Databricks. Het maakt gebruik van Parquet data bestanden met een file-based transaction log voor ACID transactions. (Microsoft, [2024c](#))

2.5.2. Delta Live Tables

Delta Live Tables is een framework voor het bouwen van processing pipelines. Hierbij wordt er gebruik gemaakt van streaming tables en materialized views. Streaming tables zijn Delta tables waarbij er extra support is voor streaming of incremental data processing en materialized views zijn views waarbij de resultaten pre-computed zijn. (Microsoft, [2024a](#))

3

Methodologie

3.1. Literatuuronderzoek

In het literatuuronderzoek zijn we in detail op zoek gegaan naar de mogelijkheden die er zijn om ETL's en ELT's te gaan implementeren. Hierbij houden we rekening dat Net IT met Microsoft producten werkt waardoor er vooral naar Azure gekeken wordt. Er is dus ook verder in detail gegaan op deze Azure producten doordat deze meer aan bod komen in de bachelorproef.

3.2. Long list

Hier alle mogelijkheden voor het implementeren van ETL's/ELT's opnoemen? Dit kan een lange lijst worden met mogelijkheden die niet relevant zijn voor Net IT aangezien er van Azure gebruik gemaakt wordt. Is dit een stap die dus overgeslaan kan worden?

3.3. Short list

Op basis van de long list houden we twee mogelijkheden over voor het implementeren van ELT's en ETL's. Dit zijn Azure Data Factory en Azure Databricks. Er is gekozen voor deze twee technologieën doordat deze beide van Azure zijn.

3.4. Vergelijkingscriteria

3.4.1. Kostprijs

3.4.2. Performantie

3.4.3. Mogelijkheid tot debuggen

3.4.4. Verschil in implementatietijd

3.4.5. Moeilijkheidsgraad in opzet

3.4.6. Mogelijkheden van de tool

3.4.7. Onderhoudbaarheid

3.4.8. Testbaarheid

3.5. Proof-of-concepts

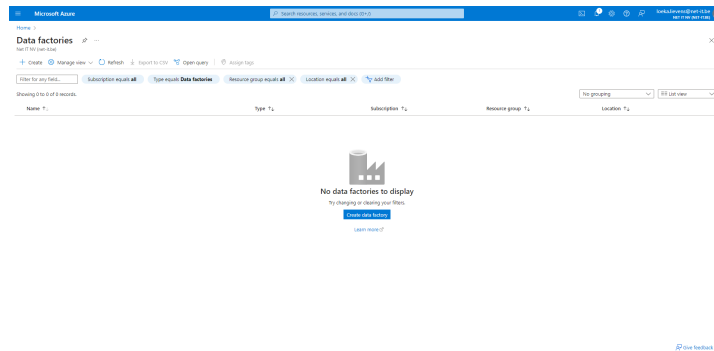
Binnen Net IT wordt data van Microsoft 365 Customer Engagement geëxporteerd naar CSV bestanden en in Azure Data Lake geplaatst. Deze bestanden moeten minstens één keer per dag opgesplitst worden per groep per jaar en zullen moeten doorgestuurd worden naar de klant. Hiervoor moet er dus een ETL of ELT geïmplementeerd worden. Doordat er onderzocht zal worden naar wat de beste mogelijkheid is voor het implementeren van deze ETL of ELT zal er dus een proof-of-concept uitgewerkt worden voor zowel Azure Data Factory en Azure Databricks. Voor het implementeren van deze proof-of-concepts zal er een pipeline gemaakt worden die ook bij de klant gebruikt wordt. Belangrijk hierbij is dat er voor deze bachelorproef gebruik gemaakt zal worden van dummy data.

De tabellen uit data lake die gebruikt worden zijn 'new_syndicalpremiumrequest', 'new_person', 'new_bankaccount', 'new_year', 'new_membership', 'new_group' en 'new_organizationyear'. Voor zowel Data Factory als Databricks zal er eerst gekeken worden naar hoe deze opgezet kunnen worden. Vervolgens zal er gekeken worden naar hoe er samen gewerkt kan worden en hoe source control geïmplementeerd kan worden. Daarnaast zal er gekeken worden hoe men data kan ophalen uit data lake met behulp van het Common Data Model en zullen de belangrijkste transformaties overlopen worden. Op deze manier kan Data Factory en Databricks makkelijk vergeleken worden.

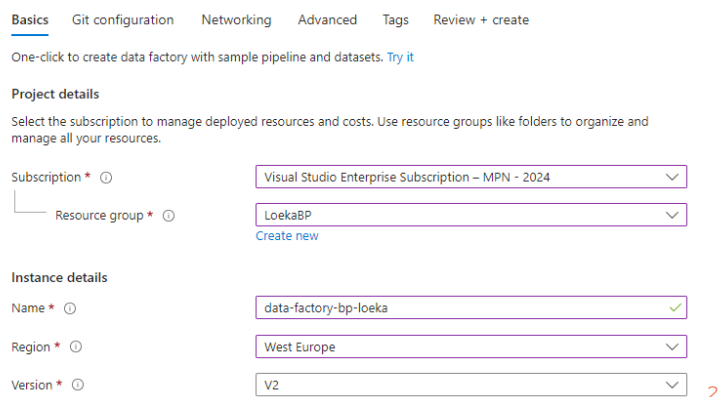
Er zal steeds gewerkt worden vanuit de tabel 'new_syndicalpremiumrequest'. Dit zijn de premies die geëxporteerd worden vanuit Microsoft 365 Customer Engagement. Deze premies zullen dus opgesplitst worden per groep, per jaar. Voor de pipelines die nu geïmplementeerd worden, worden de premies naar één CSV bestand geëxporteerd. Dit zodat het geëxporteerde CSV bestand van Data Factory dan makkelijk vergeleken kan worden met het geëxporteerde CSV bestand van Databricks.

3.5.1. Azure Data Factory (ADF)

Opzet van resources



Door in Microsoft Azure naar Data Factories te navigeren kunnen we een nieuwe data factory gaan aanmaken.



Bij het aanmaken van een data factory moet er een subscription en resource group gekozen worden. Er kan een nieuwe resource group aangemaakt worden of een reeds bestaande gekozen worden. Daarnaast moet er een naam, gewenste regio en versie voor Data Factory gekozen worden. Git configuratie zal later aan bod komen. Data Factory kan nu aangemaakt worden.



Wanneer de resource is aangemaakt kan Azure Data Factory opgestart worden.

¹Aanmaken van Azure Data Factory

²Configuratie van Azure Data Factory

³Deployment complete van Azure Data Factory

Collaboration en source control

Binnen Azure Data Factory kan er op 2 manieren samen gewerkt worden.

Add role assignment ...

Role Members Conditions Review + assign

A role definition is a collection of permissions. You can use the built-in roles or you can create your own custom roles. [Learn more](#)

Job function roles Privileged administrator roles

Grant access to Azure resources based on job function, such as the ability to create virtual machines.

data factory × Type: All Category: All

Name ↑↓	Description ↑↓
Data Factory Contributor	Create and manage data factories, as well as child resources within them.

Showing 1 - 1 of 1 results.

Door de bij de resource group van de data factory de Data Factory Contributor role toe te wijzen kan men toegang geven tot volgende zaken:

- Het aanmaken, wijzigen en verwijderen van data factories en child resources
- Deployment van Resource Manager templates
- Het managen van App Insight alerts voor Data Factory
- Het aanmaken van support tickets

Daarnaast kan er ook samen gewerkt worden via source control. Azure Data Factory laat het toe om een Git repository te configureren via Azure Repos of GitHub.

Configure a repository

Specify the settings that you want to use when connecting to your repository.

Repository type ⓘ

Azure DevOps Git

☒ Cloud ⓘ ☐ Cloud (cross-tenant sign-in) ⓘ ☐ Server (on-premise) ⓘ

Microsoft Entra ID ⓘ

Net IT NV (118054c8-f9ce-4058-a30c-77ee43ef2918)

We kiezen voor Azure DevOps doordat er binnen Net IT hiermee gewerkt wordt.

⁴Toewijzen van Data Factory Contributor Role

⁵Configuratie van Git in Azure Data Factory

Configure a repository

Net IT NV (118054c8-f9ce-4058-a30c-77ee43ef2918)

Specify the settings that you want to use when connecting to your repository.

☒ Select repository ☐ Use repository link

Azure DevOps organization name * ⓘ

loekalievns

Project name * ⓘ

Example Data Factory

Repository name * ⓘ

Example Data Factory

Collaboration branch * ⓘ

main

Publish branch * ⓘ

adf_publish

Root folder * ⓘ

/

Custom comment

☒ Use custom comment

Import existing resources

☒ Import existing resources to repository

Import resource into this branch ⓘ

6

De collaboration branch is de enigste branch waarbij de publish knop zichtbaar zal zijn. Door te werken met feature branches en hiermee pull requests te maken op de collaboration branch kan er dus samen gewerkt worden. De publish branch is de branch waar alle ARM templates van de gepubliceerde factory opgeslaan wordt.

Ophalen van data uit Azure Data Lake

Het ophalen van data uit Data Lake in Data Flow zal steeds op dezelfde manier gebeuren.

⁶Configuratie van Azure DevOps in Azure Data Factory

source1

Columns:
0 total

Source settings | Source options | Projection | Optimize | Inspect | Data preview

Output stream name * source1 [Learn more](#)

Description Add source dataset [Reset](#)

Source type * Dataset Inline

Inline dataset type * com

Linked service * Azure Database File **Common Data Model** Generic protocol Services and apps

Options

Sampling * ⓘ

7

Als source type zal er steeds gekozen worden voor inline. Dit doordat we slechts werken met één enkele dataflow en geen gedeelde datasets nodig hebben. Als inline data set type kiezen we voor Common Data Model.

New linked service

Search

All Azure File

Amazon S3 **Azure Data Lake Storage Gen2** Google Cloud Storage

Microsoft Fabric Lakehouse

New linked service

Azure Data Lake Storage Gen2 [Learn more](#)

To avoid publishing immediately to Data Factory, please use Azure Key Vault to retrieve secrets securely. [Learn more here](#)

Name * AzureDataLakeStorage3

Description

Connect via integration runtime * ⓘ AutoResolveIntegrationRuntime

Authentication type Account key

Account selection method ⓘ From Azure subscription Enter manually

Azure subscription ⓘ Visual Studio Enterprise Subscription - MPN - 2024 (46ea3764-ea2f-42ee-9b84-2d47...

Storage account name * stlftestbploeke

Test connection ⓘ To linked service To file path

Annotations

+ New

> Parameters

> Advanced ⓘ

Continue Cancel

Create Back [Test connection](#) Cancel

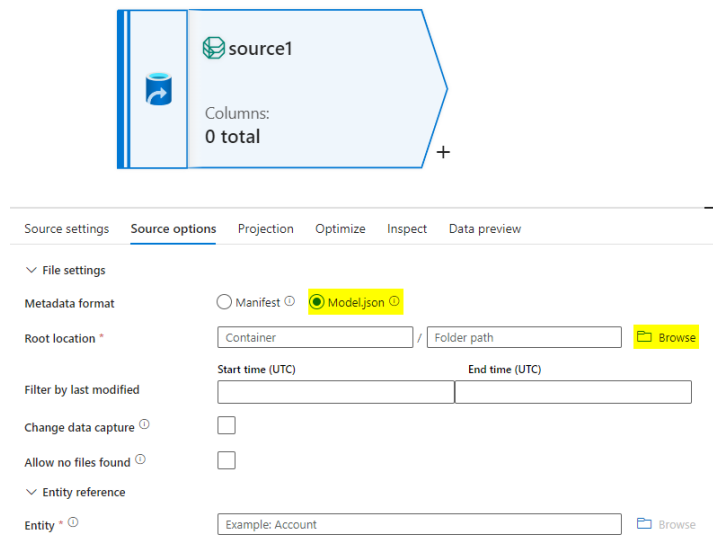
8

⁷Configuratie van source transformation

⁸Configuratie van linked service

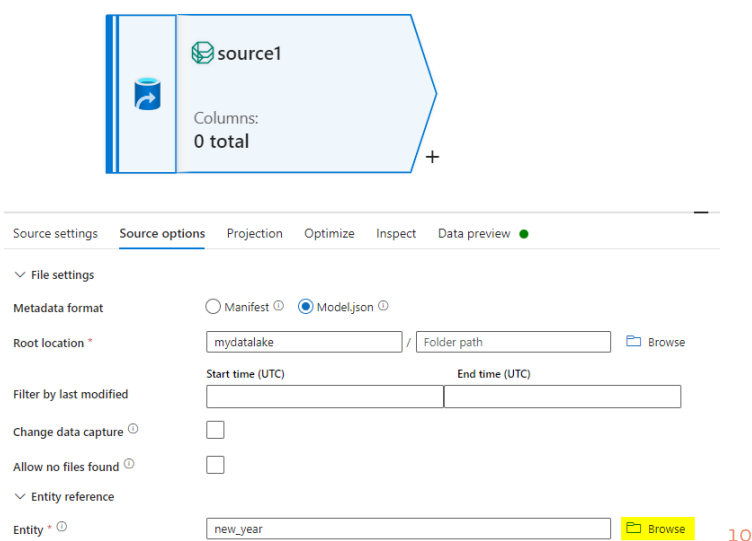
Er zal éénmalig een Linked Service aangemaakt moeten worden. Hierbij kiezen we voor Azure Data Lake Storage Gen2. We kunnen makkelijk gaan koppelen met de juiste data lake door een Azure Subscription en Storage account name aan te duiden. Door op 'Test connection' te klikken kunnen we kijken of de connectie met data lake is gelukt. Door op 'Create' te klikken hebben we nu een Linked Service die steeds bij elke Source gebruikt kan worden.

Let op: Doordat Git geen secrets opslaat is het aanbevolen om gebruik te maken van Azure Key Vault voor het opslaan van connection strings of passwords.



The screenshot shows the 'Source options' tab for a linked service named 'source1'. The 'Metadata format' is set to 'Model.json'. The 'Root location' is set to 'Container' with a 'Folder path' field. The 'Entity' field is set to 'Example: Account'. The 'Data preview' tab is also visible.

Door naar 'Source options' te gaan kunnen we 'Model.json' gaan aanduiden. Door op 'Browse' te klikken kunnen we aanduiden waar het Model.json bestand te vinden is in data lake.

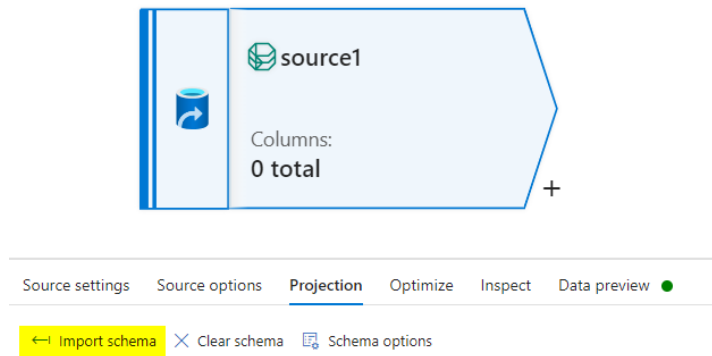


The screenshot shows the 'Source options' tab for a linked service named 'source1'. The 'Metadata format' is set to 'Model.json'. The 'Root location' is set to 'mydatalake' with a 'Folder path' field. The 'Entity' field is set to 'new_year'. The 'Data preview' tab is also visible.

⁹Configuratie van source options

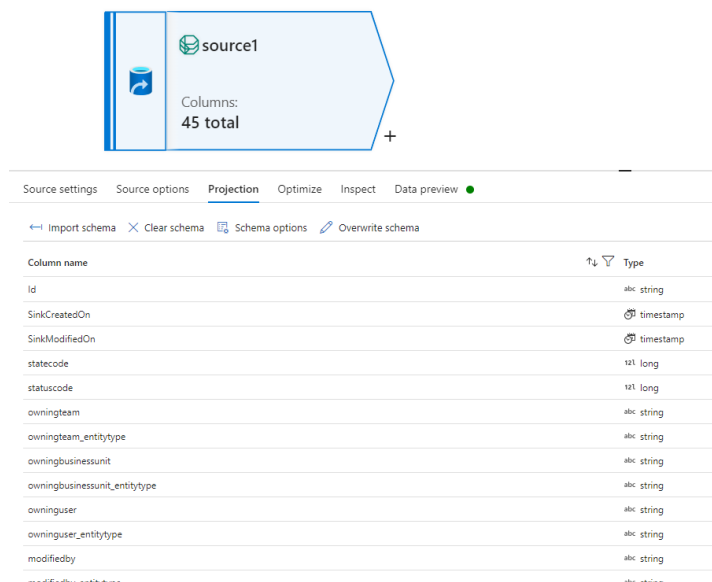
¹⁰Configuratie van source options

Naast 'Entity' kunnen we nu op 'Browse' klikken om de gewenste entity te gaan importeren. Let op: hier voor zal Data flow debug aan moeten staan.



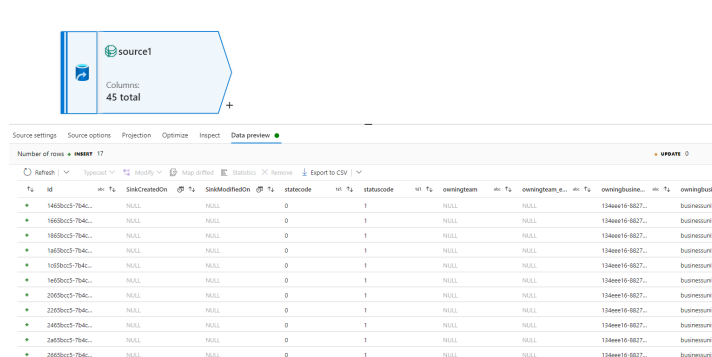
11

Door naar 'Projection' te gaan kunnen we nu op 'Import schema' klikken.



12

De foto hierboven toont een voorbeeld van een geïmporteerd schema.



13

¹¹Configuratie van projection

¹²Configuratie van projection

¹³Data preview

Wanneer we naar 'Data preview' gaan kunnen we een preview zien van de data uit de gekozen tabel.

Belangrijkste transformaties

Determinatie van welke groepen de premie in hun bestand krijgen



Join settings | Optimize | Inspect | Data preview

Output stream name * [Learn more](#)

Description [Reset](#)

Left stream *

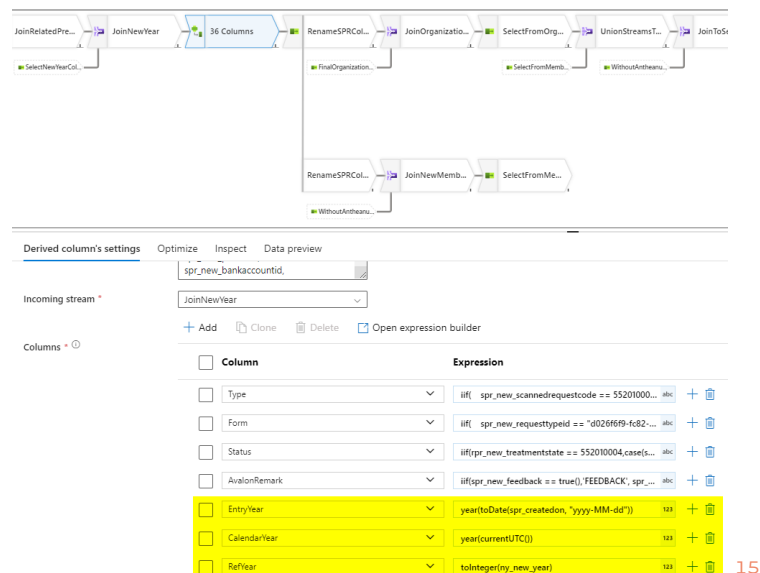
Right stream *

Join type * ☒ Full outer ☐ Inner ☒ Left outer ☐ Right outer ☐ Custom (cross)

Use fuzzy matching ☐

Join conditions *
 Left: JoinRelatedPremiumRequest's column Right: SelectNewYearColumns's column

De tabel 'new_syndicalpremiumrequest' heeft een kolom 'spr_new_yearid'. Om te gaan bepalen wat het referentiejaar van deze premie is zal dus de tabel 'new_year' op de tabel 'new_syndicalpremiumrequest' gejoind moeten worden aan de hand van dit id.



Derived column's settings | Optimize | Inspect | Data preview

Incoming stream *


Columns *

Column	Expression
Type	<code>if (spr_new_scannedrequestcode == 55201000...</code>
Form	<code>if (spr_new_requesttypeid == "d026f6f9-fc82-...</code>
Status	<code>if (spr_new_treatmentstate == 552010004, case(...</code>
AvalonRemark	<code>if (spr_new_feedback == true(), 'FEEDBACK', spr_...</code>
EntryYear	<code>year(toDate(spr_createdon, 'yyyy-MM-dd'))</code>
CalendarYear	<code>year(currentUTC())</code>
RefYear	<code>toInteger(ny_new_year)</code>

¹⁴Join van de tabel 'new_year' op de tabel 'new_syndicalpremiumrequest'

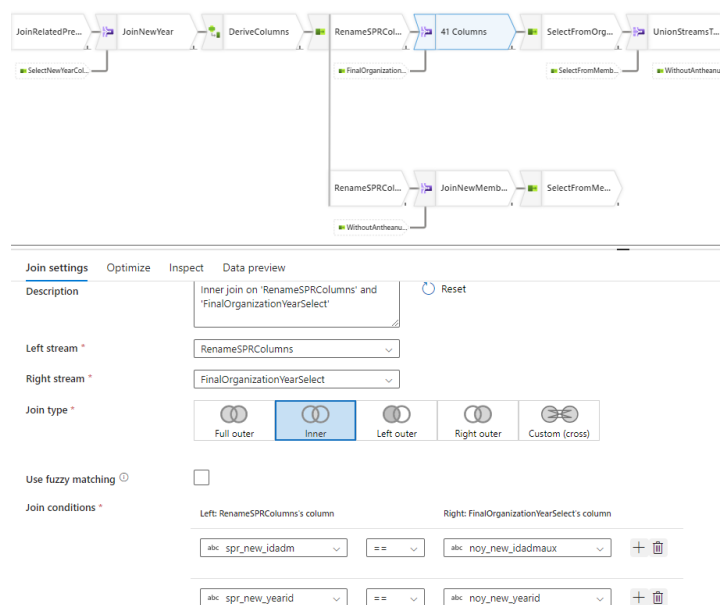
¹⁵Derive EntryYear, CalendarYear en RefYear op de tabel 'new_syndicalpremiumrequest'

Voor het bepalen van de groepen moeten hebben we 3 nieuwe kolommen nodig. Als eerste hebben we het EntryYear nodig, dit is het jaartal van 'spr_createdon', de datum wanneer de record is aangemaakt. Daarnaast hebben we CalendarYear nodig, dit is het jaartal van de huidige datum. En ten slotte hebben we RefYear nodig, dit is het jaartal van de tabel 'new_year' die net gejoind is geweest.



16

Vervolgens worden bepaalde kolommen van naam hernoemt. Welke kolommen dit zijn is onbelangrijk voor deze transformatie. Wat wel belangrijk is dat de pipeline zich nu opsplitst in twee aparte branches. Dit doordat er 2 inner joins zullen gebeuren.

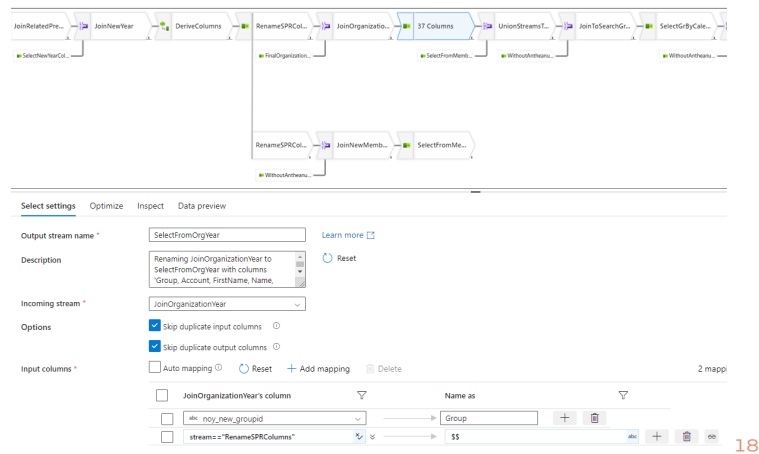


17

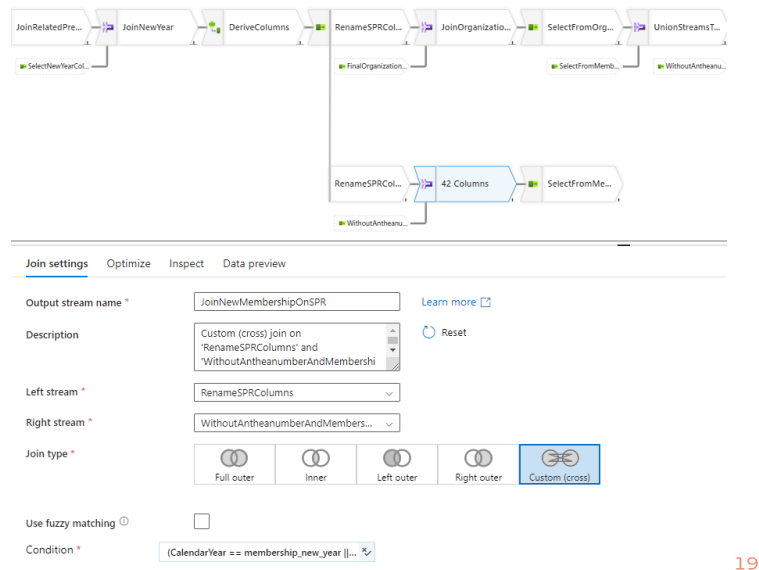
Er gebeurt nu een inner join van de tabel 'new_organizationyear' op de tabel 'new_syndicalpremium'. Hierbij wordt er aan de hand van IDADM en het id van het referentiejaar gejoind.

¹⁶Hernoemen van 'new_syndicalpremiumrequest' kolommen en splitsing in twee aparte branches

¹⁷Inner join van 'new_organizationyear' op de tabel 'new_syndicalpremiumrequest'



Vervolgens worden alle kolommen die er voor de join waren geselecteerd. Daarnaast wordt er één kolom 'noy_new_groupid' geselecteerd en hernoemd naar 'Group'.



Bij de tweede branch wordt de tabel 'new_membership' gejoind op de tabel 'new_syndicalpremiumrequest'. Er wordt gebruik gemaakt van een custom (cross) join doordat er OR condities worden gebruikt.

```
(CalendarYear == membership_new_year || EntryYear == membership_new_year || RefYear == membership_new_year)
&& spr_new_personid == membership_new_personid
```

In de conditie van de custom (cross) join wordt er vergeleken of CalendarYear, EntryYear of RefYear overeenkomt met het jaartal van de membership. Daarnaast wordt er ook gekeken of personid overeen komt.

¹⁸Selecteren en hernoemen van kolommen op de tabel 'new_syndicalpremiumrequest'

¹⁹Custom (cross) join van 'new_membership' op de tabel 'new_syndicalpremiumrequest'

²⁰Conditie van de custom (cross) join van 'new_membership' op de tabel 'new_syndicalpremiumrequest'

Select settings Optimize Inspect Data preview

Output stream name * [Learn more](#)

Description [Reset](#)

Incoming stream *

Options ☒ Skip duplicate input columns ☒ Skip duplicate output columns

Input columns * ☐ Auto mapping [Reset](#) [Add mapping](#) [Delete](#) 3 mappi

JoinNewMembershipsOnSPR's column	Name as
membership_new_groupid	Group
ng_new_groupprefix	ng_new_groupprefix
streams = "RenameSPRColums"	\$\$

Ook na deze join worden alle kolommen die er voor de join waren geselecteerd. Daarnaast wordt er 1 kolom 'membership_new_groupid' geselecteerd en hernoemd naar 'Group'. Ten slotte wordt de kolom 'ng_new_groupprefix' geselecteerd maar dit heeft te maken met een andere transformatie.

Union settings Optimize Inspect Data preview

Output stream name * [Learn more](#)

Description [Reset](#)

Incoming stream *

Union by * ☒ Name ☐ Position

Union with * [+](#) [-](#)

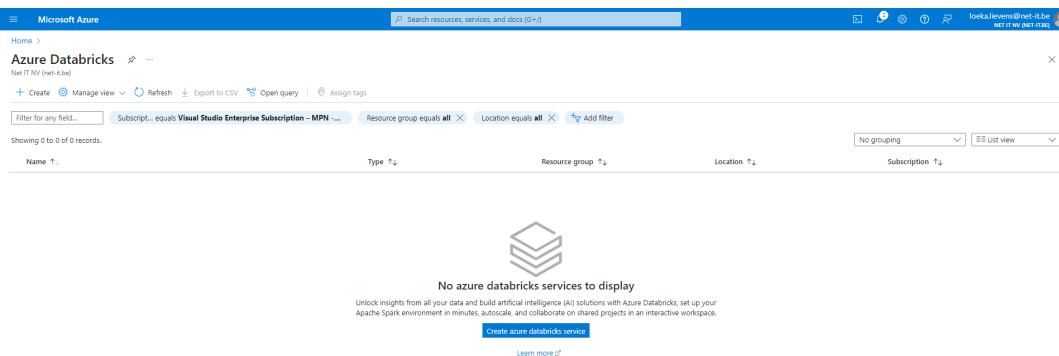
Beide branches hebben nu dezelfde kolommen met een extra kolom 'Group'. Daarnaast heeft de onderste branch nog één extra kolom 'ng_new_groupprefix'. De beide branches worden nu samen gevoegd met behulp van een union. De bovenste branch die de kolom 'ng_new_groupprefix' niet heeft zal voor deze kolom de waarde 'NULL' krijgen in de records komende van deze branch.

3.5.2. Azure Databricks

²¹Selecteren en hernoemen van kolommen op de tabel 'new_syndicalpremiumrequest'

²²Union van twee branches

Opzet van resources




[Give feedback](#) 23


Door in Microsoft Azure naar Databricks te navigeren kunnen we een nieuwe Azure Databricks workspace gaan aanmaken.

Basics Networking Encryption Security & compliance Tags Review + create


Project Details

Select the subscription to manage deployed resources and costs. Use resource groups like folders to organize and manage all your resources.


Subscription *  Visual Studio Enterprise Subscription – MPN - Spoke 2

Resource group *  LoekaBP
[Create new](#)

Instance Details

Workspace name * databricks-loeka-standard 

Region * West Europe

Pricing Tier *  Standard (Apache Spark, Secure with Microsoft Entra ID)

Managed Resource Group name databricks-loeka-standard-mrg

24

Bij het aanmaken van databricks moet er een subscription en resource group gekozen worden. Er kan een nieuwe resource group aangemaakt worden of een reeds bestaande gekozen worden. Daarnaast moet er een naam, gewenste regio en pricing tier gekozen worden. Als pricing tier kiezen we hier voor Standard doordat we geen gebruik gaan maken van Premium features. Ten slotte kan er ook een Managed Resource Group name gekozen worden. Deze resource group houdt alle resource bij die databricks nodig heeft, zoals bijvoorbeeld virtual machines, storage accounts en virtual networks.

²³Aanmaken van Azure Databricks

²⁴Configuratie van Azure Databricks

✓ Your deployment is complete

Deployment name : LoekaBP_databricks-loeka-standard
 Subscription : Visual Studio Enterprise Subscription – MPN - Spoke 2
 Resource group : LoekaBP

> Deployment details

✓ Next steps

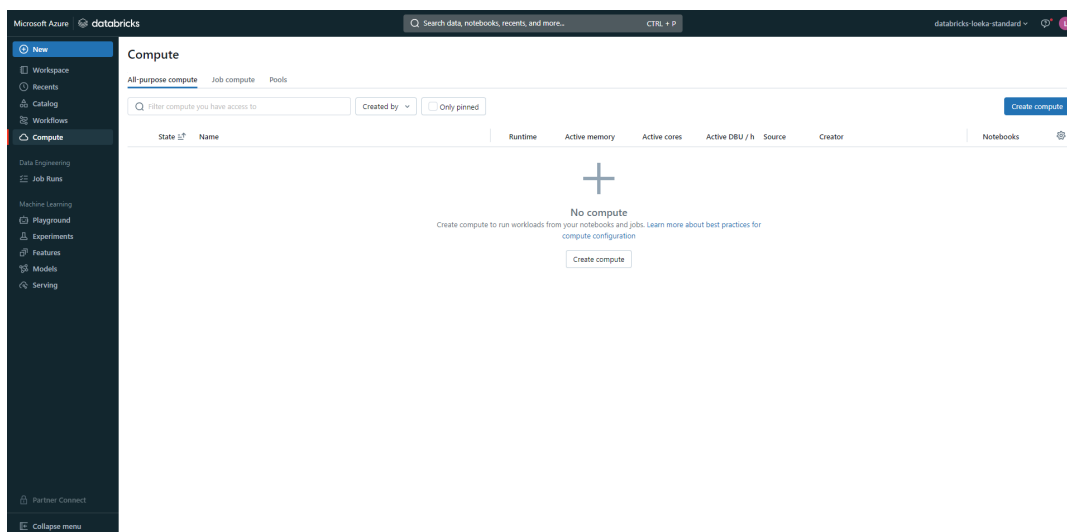
[Go to resource](#)

Give feedback

[Tell us about your experience with deployment](#)

25

Wanneer de resource is aangemaakt kan Azure Databricks opgestart worden.



26

Voor we notebooks en jobs gaan kunnen uitvoeren zullen we eerst een compute resource moeten gaan aanmaken.



²⁵Deployment complete van Azure Databricks



²⁶Aanmaken van compute resource

Compute > New compute >


Loeka Lievens's Cluster


☒ Multi node ☐ Single node


Access mode  Single user access 


Single user  Loeka Lievens 



Performance

Databricks runtime version 


Runtime: 11.3 LTS (Scala 2.12, Spark 3.3.0) 


☒ Use Photon Acceleration 


Worker type  Min workers Max workers

Standard_DS3_v2 14 GB Memory, 4 Cores  2 8 ☐ Spot instances 

Driver type

Same as worker 14 GB Memory, 4 Cores 

☒ Enable autoscaling 

☒ Terminate after 60 minutes of inactivity 

Tags

Add tags

Key Value Add

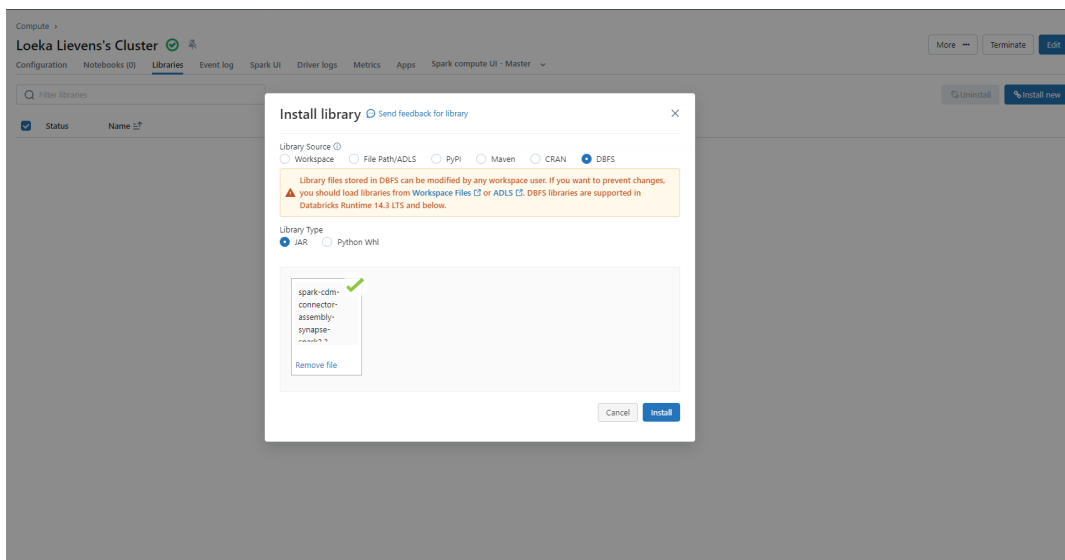
> Automatically added tags

► Advanced options

Create compute Cancel

27

De databricks runtime version moet op 11.3 LTS gezet worden zodat we Apache Spark 3.3.0 kunnen gebruiken. Dit omdat we gebruik gaan maken van 'spark-cdm-connector'. Ook hebben we ingesteld dat de cluster zichzelf zal uitschakelen na 60 minuten om onnodige kosten te voorkomen.



28

Ten slotte moet de **jar file** van 'spark-cdm-connector' geïnstalleerd worden in het

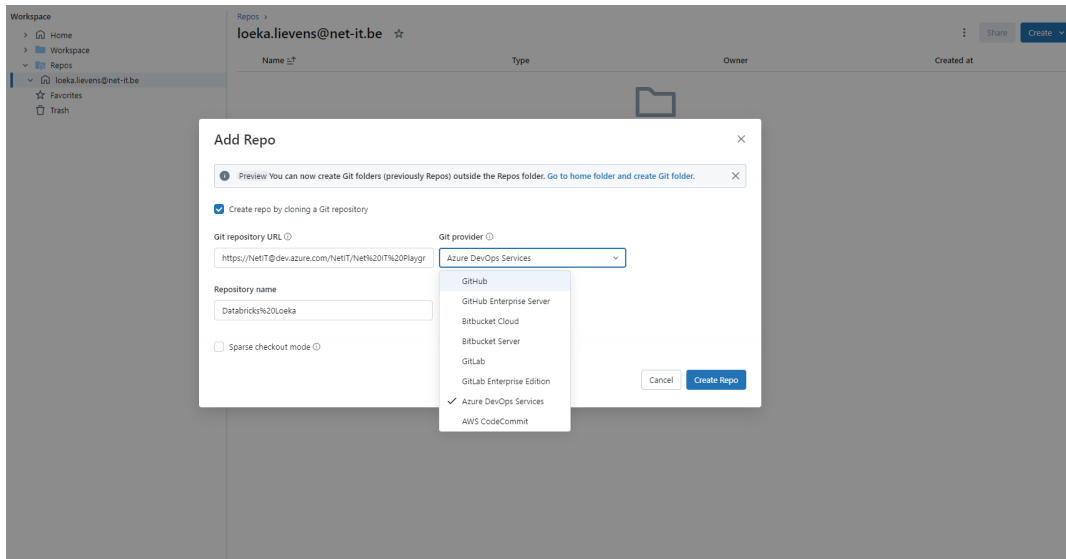
²⁷Configuratie van compute resource

²⁸Installatie van 'spark-cdm-connector'

aangemaakte compute resource om gebruik te kunnen maken van het Common Data Model in onze pipeline.


3.5.3. Collaboration en source control

Databricks folders is een visuele Git client binnen Azure Databricks om gebruik te kunnen maken van source control.




29

Het geeft de optie om verschillende Git providers te gaan gebruiken. Doordat er binnen Net IT gewerkt wordt met Azure DevOps Services zal hier voor gekozen worden.



30

Ter illustratie zal er een voorbeeld notebook aangemaakt worden.

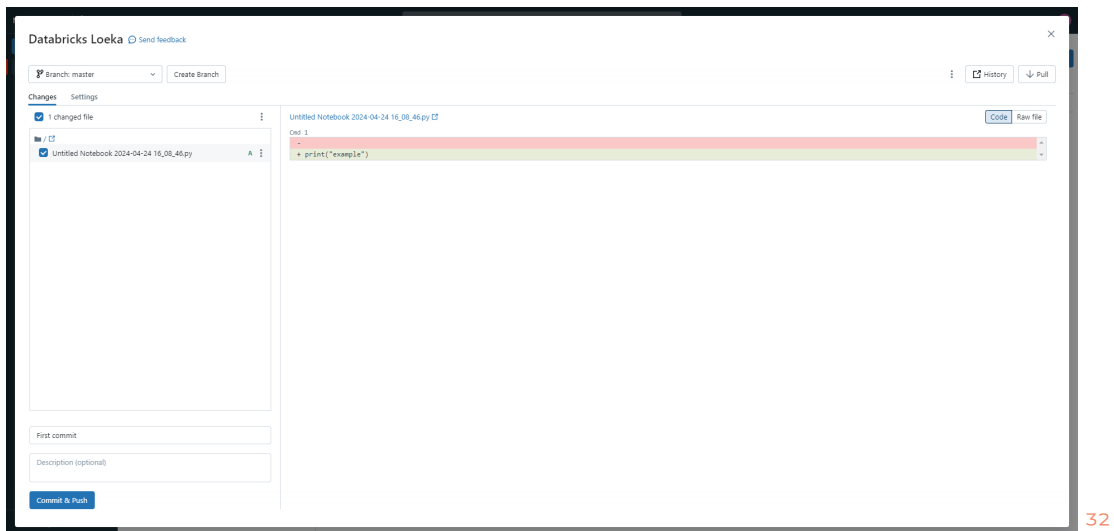


31

²⁹Clone Git repository in Databricks folders

³⁰Aanmaken van een notebook in databricks

³¹Commit en push in Databricks



Deze notebook kan dan gecommitt worden naar Git.

³²Commit en push in Databricks

4

Conclusie

Curabitur nunc magna, posuere eget, venenatis eu, vehicula ac, velit. Aenean ornare, massa a accumsan pulvinar, quam lorem laoreet purus, eu sodales magna risus molestie lorem. Nunc erat velit, hendrerit quis, malesuada ut, aliquam vitae, wisi. Sed posuere. Suspendisse ipsum arcu, scelerisque nec, aliquam eu, molestie tincidunt, justo. Phasellus iaculis. Sed posuere lorem non ipsum. Pellentesque dapibus. Suspendisse quam libero, laoreet a, tincidunt eget, consequat at, est. Nullam ut lectus non enim consequat facilisis. Mauris leo. Quisque pede ligula, auctor vel, pellentesque vel, posuere id, turpis. Cras ipsum sem, cursus et, facilisis ut, tempus euismod, quam. Suspendisse tristique dolor eu orci. Mauris mattis. Aenean semper. Vivamus tortor magna, facilisis id, varius mattis, hendrerit in, justo. Integer purus.

Vivamus adipiscing. Curabitur imperdiet tempus turpis. Vivamus sapien dolor, congue venenatis, euismod eget, porta rhoncus, magna. Proin condimentum pretium enim. Fusce fringilla, libero et venenatis facilisis, eros enim cursus arcu, vitae facilisis odio augue vitae orci. Aliquam varius nibh ut odio. Sed condimentum condimentum nunc. Pellentesque eget massa. Pellentesque quis mauris. Donec ut ligula ac pede pulvinar lobortis. Pellentesque euismod. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent elit. Ut laoreet ornare est. Phasellus gravida vulputate nulla. Donec sit amet arcu ut sem tempor malesuada. Praesent hendrerit augue in urna. Proin enim ante, ornare vel, consequat ut, blandit in, justo. Donec felis elit, dignissim sed, sagittis ut, ullamcorper a, nulla. Aenean pharetra vulputate odio.

Quisque enim. Proin velit neque, tristique eu, eleifend eget, vestibulum nec, lacus. Vivamus odio. Duis odio urna, vehicula in, elementum aliquam, aliquet laoreet, tellus. Sed velit. Sed vel mi ac elit aliquet interdum. Etiam sapien neque, convallis et, aliquet vel, auctor non, arcu. Aliquam suscipit aliquam lectus. Proin tincidunt magna sed wisi. Integer blandit lacus ut lorem. Sed luctus justo sed enim.

Morbi malesuada hendrerit dui. Nunc mauris leo, dapibus sit amet, vestibulum et, commodo id, est. Pellentesque purus. Pellentesque tristique, nunc ac pulvinar adipiscing, justo eros consequat lectus, sit amet posuere lectus neque vel augue. Cras consectetur libero ac eros. Ut eget massa. Fusce sit amet enim eleifend sem dictum auctor. In eget risus luctus wisi convallis pulvinar. Vivamus sapien risus, tempor in, viverra in, aliquet pellentesque, eros. Aliquam euismod libero a sem. Nunc velit augue, scelerisque dignissim, lobortis et, aliquam in, risus. In eu eros. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Curabitur vulputate elit viverra augue. Mauris fringilla, tortor sit amet malesuada mollis, sapien mi dapibus odio, ac imperdiet ligula enim eget nisl. Quisque vitae pede a pede aliquet suscipit. Phasellus tellus pede, viverra vestibulum, gravida id, laoreet in, justo. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Integer commodo luctus lectus. Mauris justo. Duis varius eros. Sed quam. Cras lacus eros, rutrum eget, varius quis, convallis iaculis, velit. Mauris imperdiet, metus at tristique venenatis, purus neque pellentesque mauris, a ultrices elit lacus nec tortor. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent malesuada. Nam lacus lectus, auctor sit amet, malesuada vel, elementum eget, metus. Duis neque pede, facilisis eget, egestas elementum, nonummy id, neque.



Onderzoeksvoorstel

Het onderwerp van deze bachelorproef is gebaseerd op een onderzoeksvoorstel dat vooraf werd beoordeeld door de promotor. Dat voorstel is opgenomen in deze bijlage.

A.1. Inleiding

Het implementeren van ETL's en ELT's speelt een kritieke rol in de development binnen Net IT. Net IT is een bedrijf gespecialiseerd in Customer Relationship Management (CRM). Een CRM-systeem is een applicatie om voeling te houden met klanten en om processen te stroomlijnen en meer winst te genereren. Doordat Net IT een Microsoft Partner is zullen ze CRM-toepassingen implementeren met Microsoft Dynamics 365 en intelligente bedrijfstoeepassingen met Microsoft Power Platform. Binnen Microsoft 365 Dynamics Customer Engagement worden er CSV bestanden geëxporteerd naar Azure Data Lake. Deze data wordt minstens dagelijks opgekuist, aangevuld en opgesplitst om naar de klant te kunnen doorsturen via SFTP of e-mail. Momenteel wordt dit gedaan door ETL's en ELT's te implementeren in Azure Data Factory, gebruik makend van de UI tools die aangeboden worden. Doordat dit niet de enige mogelijkheid is om dit te implementeren zal er gekeken worden naar de verschillende opties die er zijn. Aangezien Net IT een Microsoft Partner is zal er vooral gekeken worden binnen Microsoft Azure. Deze verschillende mogelijkheden zullen vergeleken worden op basis van performantie, kostprijs (voor dezelfde performantie), complexiteit, moeilijkheidsgraad in opzet en configuratie van de resources, verschil in implementatietijd en mogelijkheden van de tool. De methode die gebruikt zal worden is een gemengde aanpak gebaseerd op literatuuronderzoek en het opstellen van proof-of-concepts voor de gegeven use case van Net IT. Dit zal resulteren in een gedetailleerd vergelijkingsrapport, inclusief aanbeveling voor de meest geschikte aanpak voor het implementeren van

ETL's of ELT's voor de gegeven use case.

A.2. Literatuurstudie


Als data engineer krijgt men data in veel verschillende vormen. Het is dus noodzakelijk om deze data klaar te maken voor business analytics. (Kromer, [2022b](#)) Hier voor maakt men gebruik van ETL's en ELT's. Dit zijn processen die organisaties gebruiken voor het verzamelen en samenvoegen van data uit meerdere bronnen. Bij ETL's wordt de data getransformeerd voor het naar de doelopslagplaats geladen wordt, terwijl dit bij ELT's pas achteraf gebeurt. Daardoor staat ETL voor Extract, Transform and Load en ELT voor Extract, Load and Transform. (Bartley, [2023](#))

In Azure zijn er meerdere mogelijkheden voor het implementeren van ETL's en ELT's. Één van deze mogelijkheden is Azure Data Factory. Zoals te zien in de enquête van Sreemathy e.a. ([2021](#)) is dit de meest populaire data integratie service die aangeboden wordt door de cloud providers. Binnen Azure Data Factory kan er gebruik gemaakt worden van Mapping Data Flows, dit is een codevrije manier waarmee ETL's opgebouwd kunnen worden. De logica achter de ETL kan hierna makkelijk getest worden op live data en samples. (Kromer, [2022a](#))

Daarnaast biedt Azure ook Azure Databricks aan. Het verschil hierbij is dat de ETL's worden geïmplementeerd via code terwijl dat bij Azure Data Factory via de UI tools kan gebeurt. Azure Databricks is gebaseerd op het Apache Spark open source project. Het grote voordeel is dat het platform het toelaat om makkelijker te kunnen samen werken. Daarnaast is Apache Spark niet enkel gelimiteerd tot het maken van ETL's maar kan het ook gebruikt worden voor real-time analytics, machine learning, graph processing, etc. (Etaati, [2019](#))

Azure is niet de enigste cloud provider die ETL tools aanbiedt. Zo heeft AWS bijvoorbeeld AWS Glue (Khan e.a., [2024](#)) en Google Cloud heeft Google Data Fusion. (Jaiswal, [2022](#))

A.3. Methodologie



De eerste fase is het literatuuronderzoek. Hierbij wordt er gekeken naar welke mogelijkheden er zijn voor het implementeren van ETL's en ELT's. Er zal vooral gefocust worden op de mogelijkheden binnen Azure maar ook andere opties zullen bekeken worden. Dit zal gedaan worden met behulp van academische onderzoekstools zoals Google Scholar en andere relevante databanken en bronnen. Ook de documentatie van Azure, casestudies van bedrijven die gebruik maken van Azure en blogs van experts op dit vakgebied zullen hier zeker bij van pas komen. Deze fase zal ook zeker in samenwerkingen met Net IT gebeuren zodat de huidige gebruikte technologieën voor het implementeren van ETL's en ELT's zeker niet uitgesloten worden. Dit onderdeel zal naar verwachting vier weken in beslag nemen.

In de tweede fase zullen de resultaten van het literatuuronderzoek samengevat worden in een long list. Dit onderdeel zal naar verwachting twee weken duren.

In de derde fase zullen de meest interessante opties uit de long list samengevat worden in een short list. Hierbij zal gekeken worden naar wat het interessantst is voor Net IT. Doordat dit een kleine fase is zal dit bij de tijd van de tweede fase horen. In de vierde fase zullen er vergelijkingscriteria opgesteld worden voor de gegeven use case door Net IT. Het is belangrijk om te weten wat er moet vergeleken worden. Belangrijk om op te merken is dat niet alles even meetbaar zal zijn. Er zal dus goed gekeken worden naar hoe de vergelijkingscriteria gemeten kunnen worden. Dit onderdeel zal naar verwachting één week duren.

In de vijfde fase zal er op basis van de short list en vergelijkingscriteria een proof-of-concept uitgewerkt worden voor elke mogelijkheid dat er binnen Azure is. Er zal een situatie (gegeven door Net IT) opgezet worden met dummy data in een data lake. Het doel is dat er op basis van deze data export bestanden zullen gemaakt worden. Dit zal de langste fase zijn en zal dus vier weken in beslag nemen.

De zesde en laatste fase, die naar verwachting één week zal duren, is de evaluatie van de opties die we hebben onderzocht. Het doel is om te tonen welke optie het beste is. Daardoor zal het resultaat van deze analyse een gedetailleerd vergelijkingsrapport zijn en een aanbeveling voor welke optie het beste is.

A.4. Verwacht resultaat, conclusie

Het resultaat zal een gedetailleerd vergelijkingsrapport zijn, inclusief aanbevelingen voor de meest geschikte aanpak voor het implementeren van ETL's of ELT's voor de gegeven use case. Daarnaast zal er ook een resultaat per vergelijkingscriteria zijn zodat Net IT zelf ook een dieper inzicht krijgt in bijvoorbeeld operationele implicaties, kostenstructuur, etc.

Bibliografie

- Bartley, K. (2023, januari 2). *What is the Difference Between ETL and ELT?* <https://rivery.io/blog/etl-vs-elt/>
- Etaati, L. (2019, juni 13). Azure Databricks. In *Machine Learning with Microsoft Technologies: Selecting the Right Architecture and Tools for Your Project* (pp. 159–171). Apress. https://doi.org/10.1007/978-1-4842-3658-1_10
- Ethan. (2024, januari 14). *100+ Best ETL Tools List Software (January 2024 Update)*. <https://portable.io/learn/best-etl-tools>
- Inmon, B. (2023, maart 31). *Understanding the Necessity of ETL in Data Integration*. <https://www.integrate.io/blog/etl-in-data-integration/>
- J., P. K. (2023, maart 6). *What is Business Analytics? Definition, Importance Examples*. <https://www.linkedin.com/pulse/what-business-analytics-definition-importance-examples-jha/>
- Jaiswal, N. (2022). Data Fusion Basics. <https://medium.com/google-cloud/data-fusion-basic-concepts-c40b09efd695>
- Khan, B., Jan, S., Khan, W., & Chughtai, M. I. (2024). An Overview of ETL Techniques, Tools, Processes and Evaluations in Data Warehousing. https://cdn.techscience.cn/files/jbd/2024/TSP_JBD-6/TSP_JBD_46223/TSP_JBD_46223.pdf
- Kromer, M. (2022a). Common ETL Pipeline Practices in ADF with Mapping Data Flows. In *Mapping Data Flows in Azure Data Factory: Building Scalable ETL Projects in the Microsoft Cloud*. https://doi.org/10.1007/978-1-4842-8612-8_5
- Kromer, M. (2022b, augustus 26). Introduction to Mapping Data Flows. In *Mapping Data Flows in Azure Data Factory: Building Scalable ETL Projects in the Microsoft Cloud* (pp. 27–50). Apress. https://doi.org/10.1007/978-1-4842-8612-8_3
- Microsoft. (2024a, maart 1). *What is Delta Live Tables?* (Microsoft, Red.). <https://learn.microsoft.com/en-us/azure/databricks/delta-live-tables/>
- Microsoft. (2024b, maart 7). *What is Azure Databricks?* <https://learn.microsoft.com/en-gb/azure/databricks/introduction/>
- Microsoft. (2024c, maart 7). *What is Delta Lake?* (Microsoft, Red.). <https://learn.microsoft.com/en-us/azure/databricks/delta/>
- Microsoft. (2024d, maart 19). *What is Azure Data Factory?* (Microsoft, Red.). <https://learn.microsoft.com/en-us/azure/data-factory/introduction>
- Pollefliet, L. (2011). *Schrijven van verslag tot eindwerk: do's en don'ts*. Academia Press.

- Rawat, S., & Narain, A. (2018, december 19). Introduction to Azure Data Factory. In *Understanding Azure Data Factory: Operationalizing Big Data and Advanced Analytics Solutions* (pp. 13–56). Apress. https://doi.org/10.1007/978-1-4842-4122-6_2
- Sreemathy, J., Brindha, R., Nagalakshmi, M. S., Suvekha, N., Ragul, N. K., & Praveenandha, M. (2021). Overview of etl tools and talend-data integration. *2021 7th International Conference on Advanced Computing and Communication Systems (ICACCS)*. <https://intapi.sciendo.com/pdf/10.2478/picbe-2023-0182>
- Vines, A., & Tanasescu, L. (2023). An Overview of ETL Cloud Services: An Empirical Study Based on User's Experience. *Proceedings of the International Conference on Business Excellence*, 17(1), 2085–2098. <https://intapi.sciendo.com/pdf/10.2478/picbe-2023-0182>